Anàlisi del conjunt de dades IMDB Movie Data

Projecte: Anàlisis d'un conjunt de dades

0378 – Seguretat i alta disponibilitat, Tema 1: Alta disponibilitat

Autors: David Coruña i Joan Molina · Data: 20/10/2026

1. Introducció

Aquest document recull les preguntes de recerca treballades sobre el conjunt de dades IMDB Movie Data (1.000 pel·lícules, 2006–2016) i el procediment seguit per respondre-les: preparació de les dades, mètode d'anàlisi, resultats i interpretació. Cada pregunta es treballa en un notebook independent (Jupyter) amb el mateix procediment de base.

2. Dataset i preparació comuna

Abans de respondre cap pregunta, totes les anàlisis parteixen de la mateixa preparació de les dades:

- Es carrega IMDB-Movie-Data.csv en un DataFrame de Pandas (1.000 files, 12 columnes).
- Es renombren les columnes amb espais i parèntesis: Runtime (Minutes) → runtime, Revenue (Millions) → revenue.
- Els valors de Revenue = 0 es converteixen en nuls (NaN), perquè representen dades desconegudes i no una recaptació real de 0.
- Les columnes Genre i Actors, que contenen diversos valors separats per comes, es converteixen en llistes per poder analitzar cada gènere o actor per separat.
- Es crea un subconjunt amb Votes ≥ 1.000, perquè les pel·lícules amb molt pocs vots (sobretot de 2016) tenen una nota poc fiable.

Pregunta 1. Diferència entre la nota del públic i de la crítica, per pel·lícula i gènere

Pregunta de recerca

Quines pel·lícules tenen més diferència entre la nota del públic i de la crítica, i quins gèneres són més propensos a aquesta diferència?

Procediment

1. Es descarten les 64 pel·lícules sense Metascore (6,4% del total).
2. Es defineix diferencia = metascore − rating×10 (ambdues en escala 0–100): negatiu vol dir que la crítica puntua més baix que el públic.
3. S'ordenen les pel·lícules pel valor absolut de la diferència per trobar els casos més extrems.
4. Es calcula la diferència mitjana per gènere (desglossant la llista de gèneres) per veure quins en són més propensos.

Resultats

- Diferència mitjana global: −8,31 punts (desviació típica 13,41): la crítica tendeix a puntuar una mica més baix que el públic.
- Casos més extrems: Collateral Beauty (6,8 públic / 23 crítica, diferència −45) i Taare Zameen Par (8,5 / 42, −43) en un sentit; Megan Is Missing (4,9 / 94, +45) en el contrari.
- Per gènere, Acció (−12,2), Romance (−11,5) i Família (−10,9) són on la crítica és relativament més dura; Història (−0,3) i Animació (−2,6) són on més s'ajusten.

Interpretació i conclusió

Té sentit que Acció i Romance siguin els gèneres amb més discrepància: prioritzen l'entreteniment per sobre de l'originalitat que valora la crítica. Historia i Animació s'ajusten més perquè solen ser projectes cuidats que agraden a tothom.

Pregunta 2. Relació entre nombre de vots i recaptació

Pregunta de recerca

Hi ha relació entre el nombre de vots a IMDb i la recaptació?

Procediment

1. Es descarten les 129 pel·lícules sense dada de Revenue.
2. Es calculen les correlacions de Pearson i Spearman entre votes i revenue.
3. Es pren Spearman com a referència principal, perquè ambdues variables tenen una distribució molt asimètrica (coeficient d'asimetria al voltant de 2,5).

Resultats

- Correlació de Pearson: 0,64 — Spearman: 0,70 (n = 871): és la correlació més forta calculada en aquest projecte.
- La relació és clarament positiva: les pel·lícules amb més vots (més populars a IMDb) tendeixen a recaptar més.
- Al gràfic de dispersió (eix de vots en escala logarítmica) la tendència ascendent és clara, encara que amb bastant dispersió.

Interpretació i conclusió

Té lògica: més espectadors signifiquen més vots i més recaptació alhora, són dues cares de la mateixa popularitat. Probablement hi ha una tercera variable darrere (pressupost de màrqueting, nombre de sales) que el dataset no recull.

Pregunta 3. Gèneres amb més recaptació mitjana i millor rating mitjà

Pregunta de recerca

Quins gèneres generen més recaptació mitjana i quins tenen millor rating mitjà?

Procediment

1. S'utilitza el subconjunt amb Votes ≥ 1.000 (notes fiables).
2. Cada pel·lícula es desglossa en els seus gèneres (explode), ja que en pot tenir diversos.
3. Es calcula la mitjana de Revenue i de Rating per gènere, filtrant només els gèneres amb almenys 20 pel·lícules.

Resultats

- Animació (191 M), Aventura (154 M) i Ciència-ficció (138 M) recapten més de mitjana.
- En nota, Biografia (7,36) i Drama (6,99) lideren; Animació (7,32) combina bé nota alta i bona recaptació.
- Acció i Fantasia recapten molt però tenen una nota només mitjana (≈6,6): els gèneres que més recapten no són sempre els més ben valorats.

Interpretació i conclusió

Animació combina bé diners i nota perquè té un públic familiar molt fidel i una producció cuidada. Acció i Fantasia depenen més de l'espectacle i la franquícia que de la qualitat percebuda.

Pregunta 4. Evolució de la durada de les pel·lícules (2006–2016)

Pregunta de recerca

Com ha canviat la durada mitjana de les pel·lícules entre 2006 i 2016?

Procediment

1. S'agrupa per Year i es calcula la mitjana, la mediana i el nombre de pel·lícules de Runtime per a cada any.

2. Es representa l'evolució de la durada mitjana i mediana en un gràfic de línies.
3. Es compara amb el nombre de pel·lícules disponibles per any, per detectar si el desequilibri de dades pot distorsionar la tendència.

Resultats

- La durada mitjana baixa de 120,8 minuts (2006) a 107,4 minuts (2016): uns 13 minuts menys en una dècada.
- La baixada no és constant: hi ha un repunt el 2012 (119,1 min) abans de tornar a baixar.
- 2016 representa gairebé el 30% del dataset (297 de 1.000 pel·lícules) enfront de només 44 el 2006, cosa que pesa molt en la mitjana global.

Interpretació i conclusió

La baixada sembla real, però cal anar amb compte: 2016 és el 30% del dataset i pesa molt en la mitjana. Podria tenir relació amb l'auge de l'streaming, però amb aquestes dades no es pot assegurar.

Pregunta 5. Directors amb millor rating i amb més recaptació total

Pregunta de recerca

Quins directors tenen millor rating mitjà i quins recapten més en total?

Procediment

1. S'utilitza el subconjunt amb Votes ≥ 1.000.
2. Es agrupa per Director i es calcula el nombre de pel·lícules, el rating mitjà i la recaptació total.
3. S'exigeix un mínim de 3 pel·lícules per director perquè la mitjana sigui representativa.

Resultats

- Per rating mitjà destaquen Christopher Nolan (8,68, 5 films), Martin Scorsese (7,92) i Quentin Tarantino (7,90).
- Per recaptació total destaquen J.J. Abrams (1.683 M), David Yates (1.631 M) i Christopher Nolan (1.515 M, 3r lloc).
- Christopher Nolan és l'únic director que apareix destacat a totes dues llistes; la resta de directors amb millor nota no coincideixen amb els que més recapten, i viceversa.

Interpretació i conclusió

Que Nolan destaqui en nota i en recaptació no és casualitat: manté un segell d'autor reconegut treballant amb pressupostos de blockbuster. Cal recordar que la recaptació total afavoreix qui té més pel·lícules al dataset.

Pregunta 6. Actors amb més aparicions i la seva relació amb recaptació i rating

Pregunta de recerca

Quins actors apareixen en més pel·lícules del top 1000, i la seva presència s'associa a més recaptació o millor nota?

Procediment

1. S'utilitza el subconjunt amb Votes ≥ 1.000.
2. Es desglossa la llista d'actors (explode) per tenir una fila per cada combinació pel·lícula–actor.
3. Es calcula el nombre de pel·lícules, el rating mitjà i la recaptació mitjana per actor; després es filtra als actors amb almenys 8 pel·lícules per comparar la recaptació mitjana.

Resultats

- Els actors amb més pel·lícules al dataset són Mark Wahlberg (15), Hugh Jackman (14), Brad Pitt i Christian Bale (13 cadascun).
- Aparèixer sovint no implica millor recaptació mitjana: Mark Wahlberg (15 films) té una mitjana de 99,9 M, mentre que Robert Downey Jr. (12 films) arriba a 262,3 M i Jennifer Lawrence (11 films) a 219,2 M.
- Robert Downey Jr. també destaca en rating (7,50 de mitjana), el més alt entre els actors amb més aparicions.

Interpretació i conclusió

Aparèixer sovint no es tradueix en més recaptació perquè depèn del tipus de projecte: Downey Jr. o Lawrence concentren la seva filmografia en grans sagues (Marvel, Hunger Games), que per si soles garanteixen taquilla. És la franquícia qui empeny els números, més que l'actor en si.

3. Conclusions generals

Els vots prediuen la recaptació molt millor que el rating (0,70 enfront de 0,22), i públic i crítica coincideixen de mitjana però amb excepcions notables per gènere (Acció, Romance). El gènere i el director pesen més que l'actor individual: Animació combina bé nota i diners, i Nolan és l'únic director top en ambdues mètriques, mentre que la recaptació d'un actor depèn més de la franquícia que de l'intèrpret. La durada mitjana ha baixat uns 13 minuts entre 2006 i 2016, tot i que cal llegir-ho amb cautela. **Limitacions:** Revenue i Metascore tenen nuls (sobretot a pel·lícules de 2016), el dataset no té el mateix volum tots els anys (297 pel·lícules de 2016 vs. 44 de 2006) i les agrupacions per gènere o actor no són independents entre si.